

**Bitácora de Desarrollo Asistido: Tarea 6.2**

Araceli Castillo

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. García Gallardo

13 de octubre de 2026

## **Bitácora de Desarrollo Asistido: Tarea 6.2**

**Herramienta:** Claude (Anthropic), con acceso a mis carpetas y a mi repositorio. Trabajé sobre el mismo repositorio de la Tarea 6.1.

### **Las Instrucciones que Di**

Le entregué las instrucciones completas de la tarea y le pedí continuar desde la Tarea 6.1, sin empezar de cero. Para la auditoría le indiqué usar mi Skill de las Tareas 4.1 y 4.2, que se copió sin cambios en un commit propio. A la Skill le di las seis entradas que pide: objetivo «clase», clase de interés «bad», subgrupos (edad, estado civil, vivienda y trabajador extranjero) y el umbral por omisión. No elegí el modelo de antemano: pedí que la recomendación saliera de los números.

### **Decisiones que Tomó la Herramienta**

Medir el costo con la matriz original del dataset (5 por cada malo aprobado, 1 por cada bueno rechazado), porque la tarea dice que aprobar un malo cuesta más pero no da una cifra. Usar validación cruzada anidada además de la prueba reservada. Probar los tres modelos con pesos de clase balanceados para reflejar el error que preocupa. Dejar la vivienda como variable del modelo por ser financiera y no un atributo protegido; la segunda auditoría señaló que esa decisión no coincide con lo que yo le había dado como «solo para auditar», y la dejo escrita aquí como decisión mía, que puedo revisar.

### **Lo que Corrigió la Auditoría**

La primera pasada de la Skill dio 5 reprobadas. La más importante: la edad, el estado civil y la condición de trabajador extranjero eran entradas del modelo, aunque la tarea dice que las variables sensibles se usan para auditar, no para decidir. El código lo afirmaba en un

comentario, pero no lo cumplía. Se excluyeron dentro del Pipeline para todos los modelos, y el modelo elegido mejoró: detecta 0.600 de los malos en lugar de 0.547.

La auditoría también señaló que el modelo se eligió sin una regla escrita y con los mismos pliegues con que se evalúa. La regla (menor costo entre los que superan 0.70, confirmado en cinco semillas más) se escribió después de ese hallazgo, no antes de ver los resultados; lo declaro para no presentarla como un plan previo. Antes de escribirla, en la primera versión, el árbol balanceado tenía el menor costo con la semilla 42 (719); con otras cinco semillas su costo subió a 811-896 y su exactitud quedó cerca de 0.66. Sin esa comprobación habría recomendado un modelo que solo ganaba por la semilla.

Además se agregaron el umbral de disparidad y la marca de «no concluyente» para subgrupos con menos de 30 malos. La segunda pasada dio 20 aprobadas y 4 reprobadas. Siguen abiertas: la capacidad del boosting no se exploró; el umbral de 0.10 solo se justifica como valor por omisión; la evaluación usa los mismos pliegues con que se eligió (aunque la Skill comprobó que aplicar la regla dentro de cada pliegue elige lo mismo), y las variables restantes predicen en parte las excluidas.

### **Qué Verifiqué**

Que el número de la búsqueda (0.730) es optimista: la validación anidada da 0.714 y la prueba reservada 0.725. Que la elección del modelo se sostiene en seis semillas de la validación cruzada. Que barajar las variables sensibles no cambia ninguna predicción, que además quedó como prueba automática. Que pytest pasa (7 aprobadas y 1 fallo esperado) y que la Skill, al reejecutar desde cero en una copia, reprodujo los mismos números: exactitud 0.752, detección 0.600 y costo 728.

## Qué Aprendí

Que la búsqueda de hiperparámetros promete más de lo que entrega, y en este caso casi todo lo que prometía era optimismo. Que un comentario en el código que dice «solo para auditar» no prueba nada: la Skill lo verificó y estaba mal. Y que el modelo con mayor exactitud, el Random Forest, sería el peor para este negocio entre los finalistas, porque aprueba 177 créditos malos frente a 120.