

Flujo de Trabajo con Agentes Especializados: Validación Cruzada sobre German Credit

Araceli Castillo

Maestría en Inteligencia Artificial, Atlantis University

MAI 540: Machine Learning

Prof. Kevin A. García Gallardo

13 de octubre de 2026

Flujo de Trabajo con Agentes Especializados: Validación Cruzada sobre German Credit

Esta tarea repite el ejercicio de clase sobre German Credit: 1,000 solicitudes de crédito con 20 variables y una clase «bueno» o «malo» (Hofmann, 1994), de las cuales el 30 % son créditos malos. El trabajo se repartió entre tres roles que se ejecutaron como agentes separados, y se compara la validación cruzada con una partición única. Todo el código, los entregables de cada rol y su historial están en el repositorio.

Diseño del Flujo

Cada rol tiene un archivo en `.claude/agents/` con su responsabilidad, los archivos que puede y no puede tocar, y su entregable. El analista de datos completa `datos.py` y entrega un resumen numérico; no entrena modelos. El ingeniero de modelos construye el Pipeline y las métricas; no puede cambiar el esquema de validación ni declarar que su trabajo no tiene fuga. El auditor solo puede ejecutar código y escribir su reporte: encuentra, demuestra y devuelve, pero no corrige. Cada rol corrió en una conversación nueva que solo recibió su archivo de rol y los entregables anteriores, y cada entrega quedó en su propio commit.

Validación Cruzada

Se usó validación cruzada estratificada de 5 pliegues con barajado y semilla 42 (Kohavi, 1995). La codificación de las 13 variables categóricas se hizo con un `OrdinalEncoder` dentro del Pipeline, de modo que se ajusta solo con el entrenamiento de cada pliegue (Pedregosa et al., 2011). La Tabla 1 muestra los resultados. El Random Forest alcanza 0.759 de exactitud, por encima de la referencia de predecir siempre «bueno» (0.70), y varía poco entre pliegues. El árbol sin límite de profundidad queda en 0.698; con 20 semillas distintas de la validación cruzada solo supera 0.70 en 2 de 20, así que no mejora la exactitud de la referencia. Sin embargo, detecta el 53 % de los créditos malos, contra el 38 % del Random Forest. Esa diferencia depende del

umbral de decisión: con un umbral de 0.4, el Random Forest detecta el 60 % con exactitud de 0.737 y supera al árbol en ambas métricas. Este análisis es descriptivo; elegir el umbral requeriría datos que no se usen para evaluar.

Comparación con una Partición Única

Con 10 semillas de una partición 75/25 estratificada, la exactitud del árbol fue de 0.608 a 0.720 y la del Random Forest de 0.712 a 0.796 (Tabla 2). Comparando estadísticos equivalentes, el rango de las particiones únicas es 2.5 veces el de los pliegues en el árbol (0.112 frente a 0.045) y 5.6 veces en el Random Forest (0.084 frente a 0.015). Una sola partición puede quedar hasta 9 puntos por debajo de la media de la validación cruzada (árbol: 0.608 frente a 0.698) o 4 puntos por encima (Random Forest: 0.796 frente a 0.759). Con una partición desfavorable se concluiría que el Random Forest apenas supera la referencia; con una favorable, que el árbol la supera. La media de las 10 particiones queda cerca de la validación cruzada (diferencia de -0.024 en el árbol y -0.006 en el Random Forest): el problema de la partición única no es un sesgo, sino que un solo resultado puede caer en cualquier punto de ese rango.

Evaluación Crítica de la Distribución

Repartir el trabajo aportó una revisión que una sola conversación no hizo. El auditor reprodujo los resultados desde cero y aprobó fuga, etiqueta y reproducibilidad, pero reprobó la interpretación con cinco hallazgos. El más claro: el ingeniero comparaba el rango de 10 particiones con la desviación de 5 pliegues, dos estadísticos distintos que exageraban la diferencia. El auditor también encontró una frase del analista («una exactitud de 0.70 o menos no aporta nada») que los propios resultados contradicen. Para comprobar si esto lo habría detectado un solo agente, la misma tarea se dio a un agente en una sola conversación. Obtuvo exactamente los mismos números y su autoverificación dio «correcto», pero repitió el error del rango contra la

desviación. Revisó solo fuga, etiqueta y reproducibilidad, lo que ya sabía revisar, y nada de la interpretación.

El costo fue alto. La primera ronda del flujo usó 260,013 tokens y 290 segundos, contra 79,809 tokens y 77 segundos del agente único: más del triple de tokens, y la segunda ronda de correcciones no se midió. Los números no cambiaron en ningún momento; lo que se corrigió fue el texto. Además, los roles se comunican solo por archivos, así que el auditor tuvo que volver a ejecutar todo para confiar en ellos. Repetiría el flujo cuando el resultado vaya a sostener una decisión o a entregarse a otros, porque ahí importan las conclusiones y no solo los números. Para una exploración rápida o un cálculo puntual, una sola conversación basta.

Referencias

- Hofmann, H. (1994). *Statlog (German credit data)* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5NC77>
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. En *Proceedings of the 14th International Joint Conference on Artificial Intelligence* (Vol. 2, pp. 1137–1143). Morgan Kaufmann.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Tabla 1*Validación Cruzada Estratificada de 5 Pliegues*

Modelo	Exactitud media	Desv. (ddof = 1)	Malos detectados	Predice «malo»
Siempre «bueno»	0.700	—	0.000	0 %
Árbol de decisión	0.698	0.019	0.530	32 %
Random Forest	0.759	0.007	0.377	17 %

Nota. Semilla 42 en la validación cruzada y en los modelos. Detección de malos con predicciones fuera del pliegue y umbral por defecto. Con umbral 0.4 el Random Forest detecta 0.603 con exactitud 0.737.

Tabla 2*Partición Única 75/25 (Semillas 0 a 9) Frente a la Validación Cruzada*

Modelo	Mín.	Máx.	Rango particiones	Rango pliegues CV	Media – CV
Árbol de decisión	0.608	0.720	0.112	0.045	–0.024
Random Forest	0.712	0.796	0.084	0.015	–0.006

Nota. Partición estratificada. Desviación (ddof = 1): particiones 0.031 y 0.028; pliegues 0.019 y 0.007.

Tabla 3*Costo del Flujo Distribuido Frente a un Solo Agente*

Ejecución	Tokens	Tiempo	Hallazgos de interpretación
Analista + ingeniero + auditor (ronda 1)	260,013	290 s	5, todos corregidos en ronda 2
Un solo agente	79,809	77 s	0 detectados por su autoverificación

Nota. Costo reportado por la herramienta al terminar cada agente. Evidencia en evidencia/FLUJO.md.